



{LLMs et Antiquité}

Utilisation des LLMs pour les lettres classiques




Concepts de base


vecteurs statiques, vecteurs contextuels



Vecteurs statiques




Définition d'un LLM (Large Language Model)




Problèmes ?

Vous aurez besoin d'un hardware digne de ce nom (et encore)



Problèmes ?

Il y a toujours un effet boîte noire dans les LLMs : même si on a de plus en plus de possibilités de visualiser les points d'attention décisionnels, physiquement, on ne peut pas tout contrôler.



Problèmes ?

En lettres classiques :

- très peu de données
- des données vraisemblablement plus finies que les autres
- trop peu de données représentatives (hors de la période classique)

	Class	Frequency	3 Classes	Frequency
Homer	Person	2.469	PER	2
	Place	698	LOC	2
Plato	Person	12.424	PER	12
	Place	2.305	LOC	2
	Ethnic	3.548	MISC	2
	NoClass	2.263	MISC	2
	Group	681	MISC	2
	Title	206	MISC	2
	Festival	20	MISC	2
	Month	8	MISC	2
	Language	7	MISC	2
	Constellation	2	MISC	2
Total				24

Table 1: An overview of the training data set.

Ancient Greek BER1

Note: The Morphological Analysis Tag due to an issue with the FLAIR Toolkit help!



Ἀχιλλῆος	d ' Achille
Δαρδανίδαο ἤγε λαβῶν δ'	pris
ἐρινεὸν	à un figuier sauvage
φεύγοντι	qui s ' échappe
Λυκάονι	Lycaon
τόν	qu
ποτ'	naguère
αὐτός	lui - même
πατρός	de père
ἄλωῃς	verger

Word lookup

Lookup

(Latin) Change Language

Incitant

incito , incitare , incitavi , incitatus (lesser)

verb; 1st conjugation

incito: **enrage; urge on; inspire; arouse;**

incit-ant

3rd person plur: **pres. ind. act.**


Credits

Login to save your words to your wordlist. Login


EXAMPLES

LLMs
Quelques
exemples
d'expériences

1. Similarité sémantique monolingue



2. Etudes de réseaux




3. alignement de traductions


<https://github.com/OdysseusPolymetis/pyOdysseus>

<https://odysseuspolymetis.github.io/pyOdysseus/paralogos/>


4. intertextualité multilingue



Chaîne globale de ce que je propose




Résultat 1 : réduction des candidats



Résultat 2 : mesure de spécificité

Phrases grecques retenues après filtre de spécificité (0.50)





17 793 → 9 818

Le filtre de spécificité divise l'espace grec par deux tout en gardant les cibles les plus pertinentes.


Profils d'auteur après filtre de spécificité (0.50)

Euripide	Eschyle	Sophocle
Volume retenu 5 931 phrases grecques	Volume retenu 1 680 phrases grecques	Volume retenu 2 207 phrases grecques
Part du total filtré 60,4 %	Part du total filtré 17,1 %	Part du total filtré 22,5 %
Spécificité moyenne (rang) 0.738757	Spécificité moyenne (rang) 0.796699	Spécificité moyenne (rang) 0.730384
★ Euripide domine nettement en volume.	Eschyle apparaît moins fréquent mais plus spécifique en moyenne.	Sophocle reste clairement présent mais à un volume plus modeste.


Résultat 3 : scores globaux




Résultat 4 : macro au micro



★ La colonne euripides présente les valeurs les plus élevées pour la majorité des pièces : une empreinte structurelle forte.



🏆 Les rôles centraux de *Medea*, *Antigone*, *Bacchae*, *Seven Against Thebes* et *Suppliants* structurent le réseau des emprunts intertextuels.



★ Dans *Medea*, de nombreux segments montrent des parallèles forts, surtout avec *Euripide*.

Résultat 5 : rapprochements quantifiables

A Top rapprochements (final_score_ce)

- 1 Medea (seg. 331) ↔ Antigone / Sophocle 0.759077
- 2 Medea (seg. 331) ↔ Bacchae / Euripide 0.745889
- 3 Hercules Furens (seg. 307) ↔ Seven Against Thebes / Eschyle 0.733430
- 4 Oedipus (seg. 304) ↔ Ion / Euripide 0.728464

★ Meilleur score ajusté
Oedipus (seg. 103) ↔ Suppliants / Eschyle
specificity_adjusted_score_ce = 0.721542

B Effet du cross-encoder

 mean final_score 0.678534


 mean final_score_ce 0.552100

 mean ce_penalty 0.813736

 mean cross_encoder_score 0.524681


Résultat 6 : et le "je ne sais quoi" ?

1 Après ajustement de spécificité




Même après ajustement, la colonne sophocles ne disparaît pas : plusieurs pièces gardent un signal sophocléen visible.

2 Foyer local — Hercules Oetaeus




Hercules Oetaeus est l'un des foyers où le sophocléen ressort le plus nettement dans les visualisations.


3 Foyer mixte — Medea




Dans Medea, Euripide domine, mais des pics sophocléens subsistent localement.



Atelier



Mise en pratique avec l'IA



Rappel

Sur chacun des notebooks, vous avez un bouton en haut comme ça :



Vous devez appuyer dessus, ce qui ouvrira un Google Colab

(il vous faut un identifiant google)

Ensuite, n'oubliez pas de copier le notebook :

Fichier > Enregistrer une copie dans Drive

Expérience 0 : TAL avec et sans LLM

Vous trouverez tout sur le github, mais voici
le lien direct au notebook :


https://github.com/OdysseusPolymetis/atelier_humanistica2026/blob/main/0_nlp_lat_gk.ipynb

1. Analyse stylistique automatisée

Extrait de "Madame Bovary" (Flaubert)

*"Elle se demandait s'il n'y aurait pas eu moyen,
par d'autres combinaisons du hasard,
de rencontrer un autre homme..."*

Caractéristiques stylistiques




2. Attribution d'auteur


Texte d'auteur inconnu

*"[...] car ce n'est point dans les objets,
c'est en nous qu'est la passion [...]"*

Probabilité par auteur




3. Étude des influences entre textes



4. Exploration de grands corpus

10,000
textes



Expérience 1 : les vecteurs statiques

Vous trouverez tout sur le github, mais voici
le lien direct au notebook :

https://github.com/OdysseusPolymetis/atelier_humanistica2026/blob/main/1_word_vectors_from_treebank.ipynb

"A word is defined by the company it keeps"

J.R. Firth, linguiste britannique


Contexte des mots

Le **chat** mange des croquettes.

Le **chat** dort sur le canapé.

Le **chien** aboie contre le facteur.

Représentation vectorielle



Comment fonctionnent les word embeddings?


1. Chaque mot est représenté par un vecteur dans un espace à 100-300 dimensions
2. Les mots qui apparaissent dans des contextes similaires auront des vecteurs proches
3. Ces vecteurs capturent des relations sémantiques:

roi - homme + femme $\approx$ reine

chat = [0.2, -0.5, 0.8, 0.1, ...] (dans un espace à plusieurs dimensions)


Expérience 2 : les transformers, intro

https://github.com/OdysseusPolymetis/atelier_humanistica2026/blob/main/2_bases_transformers.ipynb




Expérience 3 : NER

https://github.com/OdysseusPolymetis/atelier_humanistica2026/blob/main/3_ner_lat_gk.ipynb



Expérience 4 : Topic Modeling

https://github.com/OdysseusPolymetis/atelier_humanistica2026/blob/main/4_basic_topic_modeling_bertopic.ipynb



Expérience 5 : RAG pour LLM

https://github.com/OdysseusPolymetis/atelier_humanistica2026/blob/main/5_rag_scaife_qwen.ipynb

" Thucydide décrit la guerre civile comme une situation de désespoir et de désespoir mutuel. Selon

[P1], il écrit : "Grec : 'βουλεύεσθε οὖν βραδέως ὥς οὐ περὶ βραχέων, καὶ μὴ ἀλλοτρίαις γνώμαις καὶ ἐγκλήμασι πεισθέντες οἰκεῖον πόνον πρόσθησθε.'"

Cela signifie qu'il suggère aux Athéniens de prendre des décisions lentement, sans se fier à des opinions partisans ni à des conflits, afin de préserver un effort de travail commun. Il souligne également que cette guerre civile est une situation de désespoir où les gens sont contraints de prendre des décisions difficiles, sans possibilité de trahison ou de trahison mutuelle. "

Expérience 6 : si on a le temps : alignement multilingue

https://github.com/OdysseusPolymetis/pyOdysseus/blob/main/pyOdysseus_interface.ipynb



pyOdysseus

pyOdysseus is an alignment toolkit and interface based on a modified version of [bertalign](#). It is designed for multilingual text alignment and includes notebooks for alignment, visualisation, and sentence-transformer fine-tuning.

Contents

This repository contains several types of notebooks:

- `pyOdysseus_interface.ipynb`

Références utiles (non exhaustif)

Yousef, T., Palladino, C., Shamsian, F., d'Orange Ferreira, A., & Ferreira dos Reis, M. (2022). An automatic model and Gold Standard for translation alignment of Ancient Greek. In Proceedings of the Language Resources and Evaluation Conference (pp. 5894–5905). European Language Resources Association. Marseille, France. Retrieved from <https://aclanthology.org/2022.lrec-1.634>

Nils Reimers and Iryna Gurevych. 2020. [Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4512–4525, Online. Association for Computational Linguistics.

Riemenschneider, F., & Frank, A. (2023). Graecia capta ferum victorem cepit. Detecting Latin Allusions to Ancient Greek Literature. In *Proceedings of the First Workshop on Ancient Language Processing*. Association for Computational Linguistics. Varna, Bulgaria. Retrieved from <https://arxiv.org/abs/2308.12008>

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.

MZES Data Lab. (n.d.). BERT and explainable AI. Retrieved from <https://www.mzes.uni-mannheim.de/socialsciencedatalab/article/bert-explainable-ai/>

Contact

Merci de votre attention

Colab link for experiment

marianne.reboul@ens-lyon.fr

github : OdysseusPolymetis